UNIVERSIDAD CATÓLICA BOLIVIANA “SAN PABLO”

Caso 5 - Green Building Energy Efficiency (Energía)

Integrantes:

- Lopez Castillo Kael Alessandro
- Medina Paredes Esmeralda Paula
- Torrez Calle Álvaro Ariel

Docente: Paton Gutierrez Ovidio Roger

Fecha: 11 / 03 / 2026

Materia: Machine Learning

1. Resumen Ejecutivo y Problema de Negocio

Contexto del Negocio

En el diseño de edificios sostenibles, predecir la carga de calefacción (Heating Load) desde las fases iniciales del proyecto es crucial. Una estimación precisa permite a los arquitectos optimizar la geometría del edificio, reduciendo drásticamente los costos operativos y la huella de carbono a lo largo de su vida útil.

Objetivos

Este proyecto adopta la metodología CRISP-DM para resolver dos objetivos fundamentales:

1. **Regresión:** Predecir con alta precisión la carga térmica de calefacción (variable numérica) basándose en las características arquitectónicas.
2. **Clasificación:** Categorizar automáticamente si un diseño es "Eficiente" (Heating < 14) o "No Eficiente" para agilizar la toma de decisiones.

Criterios de Negocio y Costos de Error

Asumimos que la geometría del edificio y sus proporciones son los factores iniciales más determinantes, manteniendo el clima constante para este análisis. Desde una perspectiva de negocio, el costo de un *Falso Positivo* (aprobar un edificio ineficiente creyendo que es eficiente) es severo, ya que generará altos costos energéticos y penalizaciones ambientales durante décadas. Por tanto, nuestras métricas priorizan minimizar este error a toda costa.

2. Análisis Exploratorio de Datos (Data Understanding)

Se analizó un conjunto de datos de 768 simulaciones de edificios sin valores nulos. El análisis bivariado reveló comportamientos clave en el diseño de las estructuras:

- **La variable crítica:** La altura del edificio (Overall_Height) mostró una relación escalonada y directa con la demanda energética. Los edificios más altos requieren significativamente más energía térmica.
- **Correlaciones físicas:** Se observó que ciertas variables geométricas están estrechamente ligadas, lo que influye en cómo interactúa el edificio con su entorno.

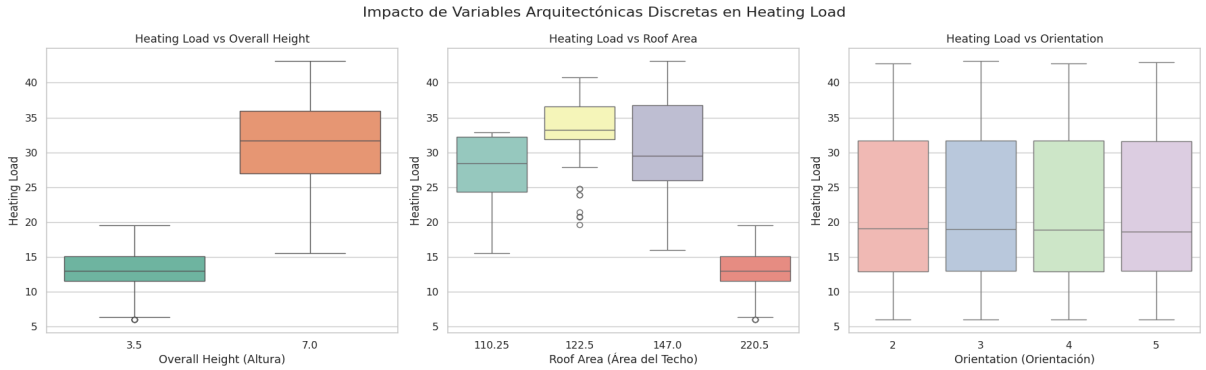

3. Preprocesamiento e Ingeniería de Características (Feature Engineering)

Para poder garantizar la validez del modelo y evitar cualquier tipo de fuga de información (Data Leakage). Desde el conjunto de prueba hacia el de entrenamiento, se implementó una metodología estricta mediante Pipelines de scikit-learn.

- **Estandarización:** Se utilizó un ColumnTransformer junto con StandardScaler para nivelar las magnitudes de las variables físicas antes de entrenar los modelos, asegurando que ninguna variable domine a otra por su escala.
- **Feature Engineering:** Nos basamos en la termodinámica de las edificaciones, creamos una nueva variable denominada Overall_Surface, es el resultado de sumar el Área del Techo y el Área de las Paredes. Esta variable representa la superficie total expuesta al clima exterior y demostró tener un altísimo poder predictivo en los modelos posteriores para calcular la pérdida de calor.

Los datos se dividieron en un 80% para entrenamiento y un 20% para pruebas, pudiendo así, validar el aprendizaje mediante validación cruzada (K-Fold = 5).

4. Modelado, Diagnóstico y Evaluación

Se evaluaron modelos base y ensambles avanzados del estado del arte para capturar las relaciones no lineales. Además, se aplicó una optimización de hiperparámetros (RandomizedSearchCV) para maximizar el rendimiento de los algoritmos.

Fase de Regresión (Predicción de Carga)

- **Regresión Lineal y Ridge:** Mostraron un desempeño aceptable (RMSE cercano a 2.9), pero sufrieron debido a la alta multicolinealidad de las variables de área. La optimización del parámetro de regularización (alpha=0.1) en Ridge no logró superar esta barrera estructural.
- **Random Forest y XGBoost Regressor:** Los modelos de ensamble superaron drásticamente a los lineales. XGBoost se posicionó como el modelo de estado del arte y ganador absoluto, minimizando el error residual casi en su totalidad tras el ajuste de hiperparámetros (learning_rate: 0.2, n_estimators: 200).

Tabla 1: Resultados de Modelos de Regresión Optimizados (Predicción de Heating Load)

Modelo Evaluado	**RMSE Promedio**	**R^2 (Coef. de Determinación)**
Regresión Lineal (Baseline)	2.9292	0.9145
Regresión Ridge (Tuned, L2)	2.9290	0.9145
Random Forest Regressor (Tuned)	0.5134	0.9974
XGBoost Regressor	**0.3644**	**0.9987**

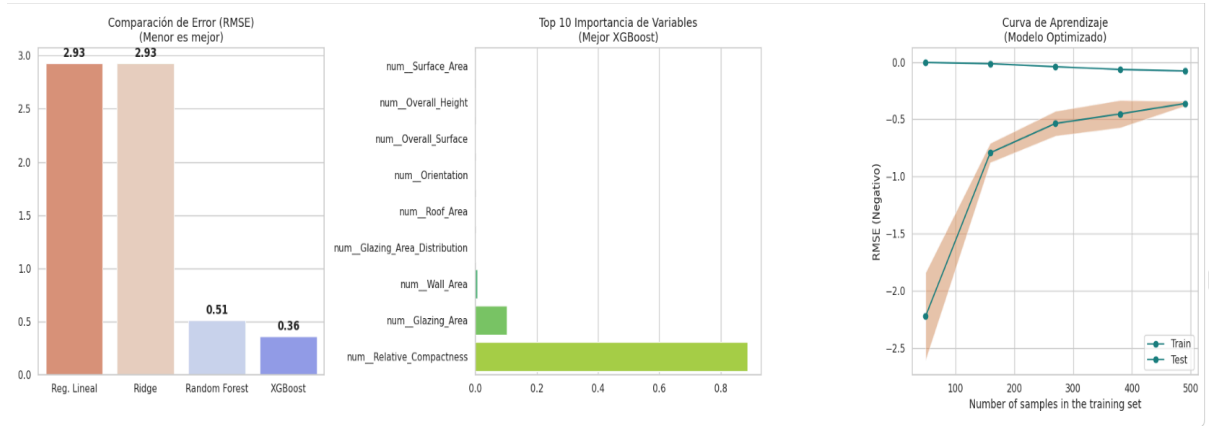

a. **Fase de Clasificación (Categorización de Eficiencia)**

Se comparó una Regresión Logística contra un Random Forest Classifier, aplicando búsqueda y optimización de hiperparámetros en ambos. El ensamble de árboles mantuvo un rendimiento superlativo en el set de prueba.

Tabla 2: Resultados de Modelos de Clasificación Optimizados (Target: Eficiente < 14)

Modelo Evaluado	**F1-Score**	**ROC-AUC**
Regresión Logística (Tuned)	0.9091	0.9865
Random Forest Classifier (Tuned)	**0.9655**	**0.9990**

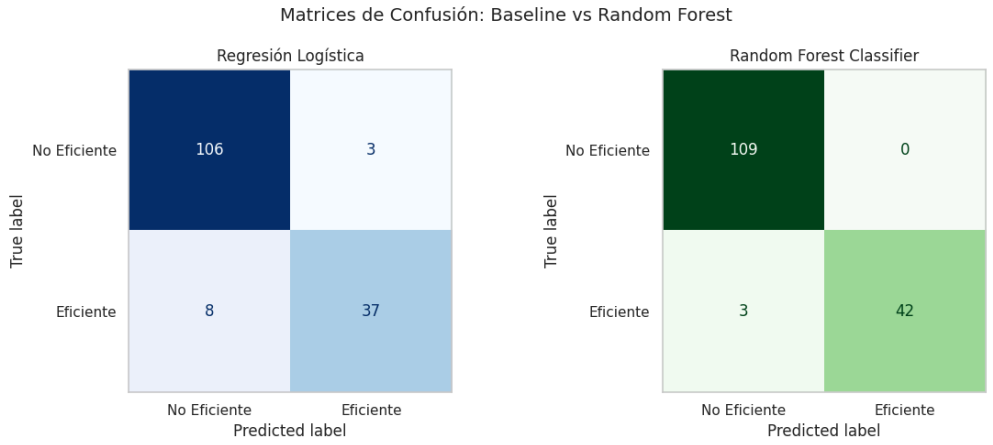

La optimización garantizó que la separación entre clases sea nítida (ROC-AUC de 0.9990). La matriz de confusión demuestra que se eliminaron por completo los **Falsos Positivos (0)**, asegurando que la consultoría no incurrirá en los costosos errores de aprobar edificios ineficientes.

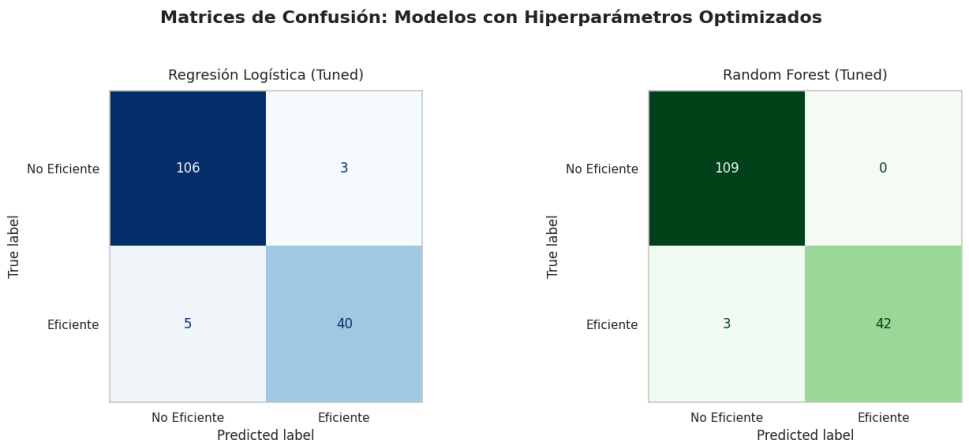

5. Supuestos del Modelo y Trade-offs

- **Supuestos del Modelo:** El análisis asume un entorno de simulación con un clima externo estático y materiales de construcción estándar.
- **Trade-offs (Compensaciones):** Al maximizar el F1-Score y el ROC-AUC en clasificación, optamos por un modelo más complejo (Random Forest) que pierde un poco de explicabilidad matemática directa (comparado con una regresión lineal), pero que a cambio elimina el riesgo de Falsos Positivos, lo cual es vital para la rentabilidad y reputación del negocio.

6. Conclusiones y Recomendaciones Accionables

Basado en los modelos predictivos evaluados, se emiten las siguientes directrices arquitectónicas para los próximos proyectos:

1. **Priorizar la Baja Altura:** La variable de mayor impacto es la altura total. Diseños de un solo piso con plantas extendidas resultan ser mucho más eficientes térmicamente que construcciones verticales y compactas de volumen equivalente.
2. **Superficie de Exposición:** La reducción del área expuesta (nuestra variable Overall Surface) es imperativa. Optimizar esta macro-geometría proporciona mayores ahorros que modificar detalles menores.
3. **Inversión Tecnológica:** El acristalamiento (Glazing Área) es secundario frente a la macro-geometría. Recomendamos agotar las optimizaciones de forma y altura antes de invertir un presupuesto elevado en ventanas de alta tecnología.
4. **Evolución del Modelo:** Para un despliegue en producción real, es esencial integrar datos sobre la zona climática local y el Valor-R (aislamiento térmico) de los materiales constructivos específicos a utilizar.