Optimización de Eficiencia Energética en Edificios

Predicción de Carga Térmica mediante Machine Learning (Enfoque CRISP-DM)

Equipo: Consultoría de Eficiencia Energética (LEED)

Integrantes:

- Lopez Castillo Kael Alessandro
- Medina Paredes Esmeralda Paula
- Torrez Calle Álvaro Ariel

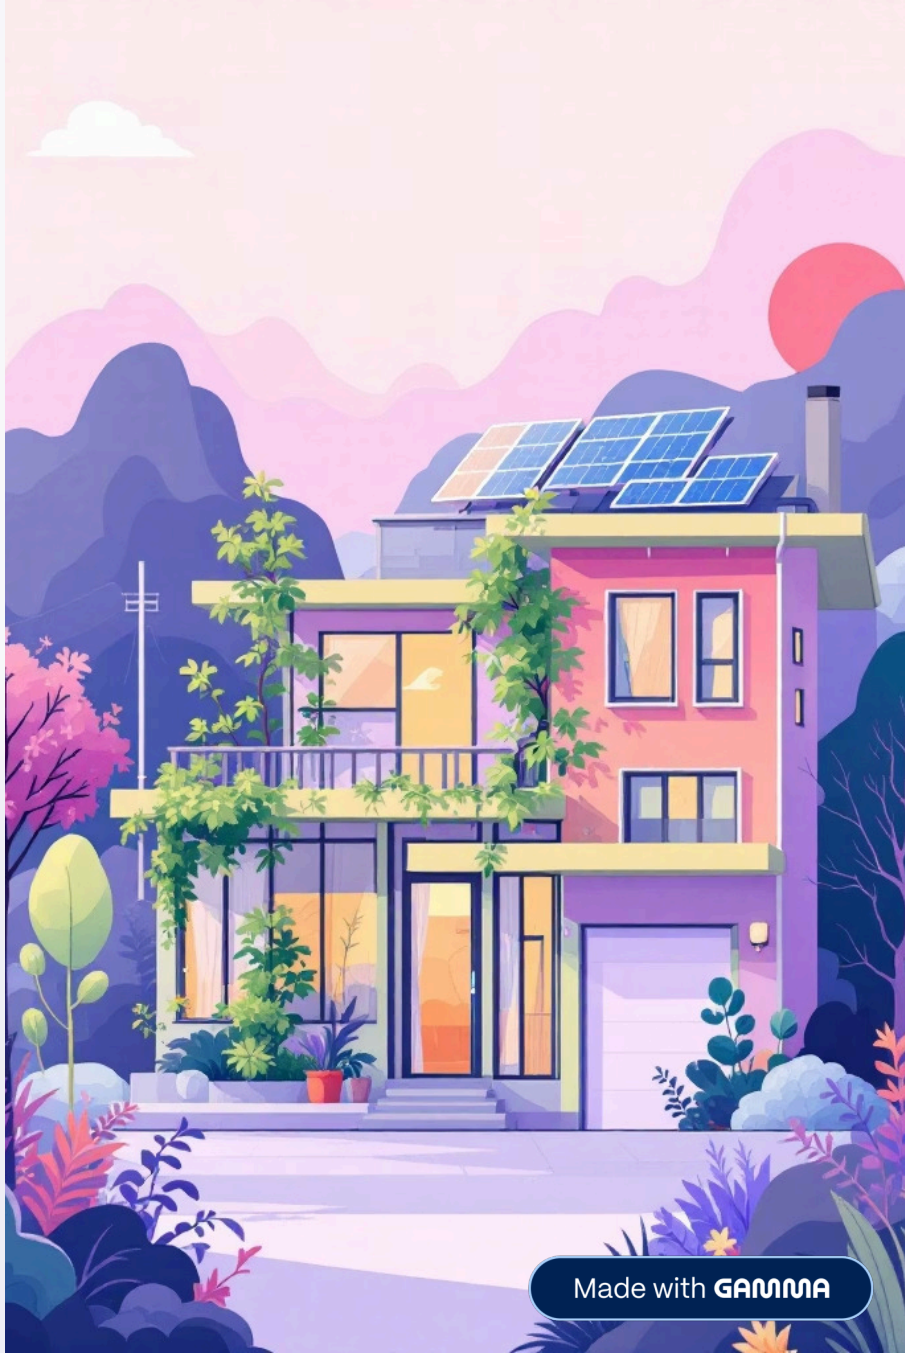

Made with GAMMA

Contexto del Proyecto

- Los sistemas de climatización (HVAC) son el mayor gasto energético en edificios residenciales.
- Existen 2 parametros que definen la ediciencia de un edificio: la carga de calefacción (HL) y la carga de refrigeración (CL).
- Tradicionalmente, esto se hace usando software de simulación de energía que consume mucho tiempo y requiere conocimientos técnicos altamente especializados.

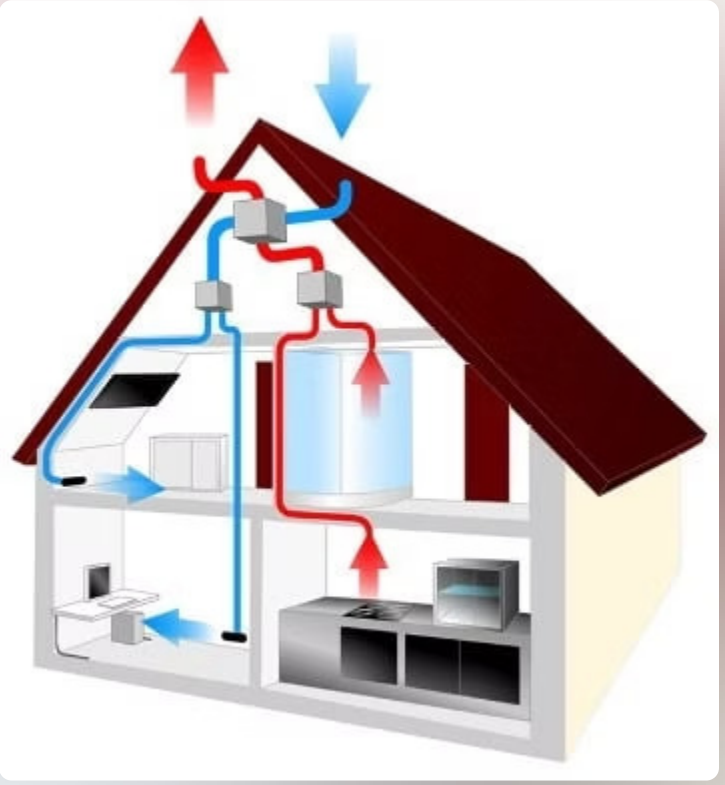

Made with GAMMA

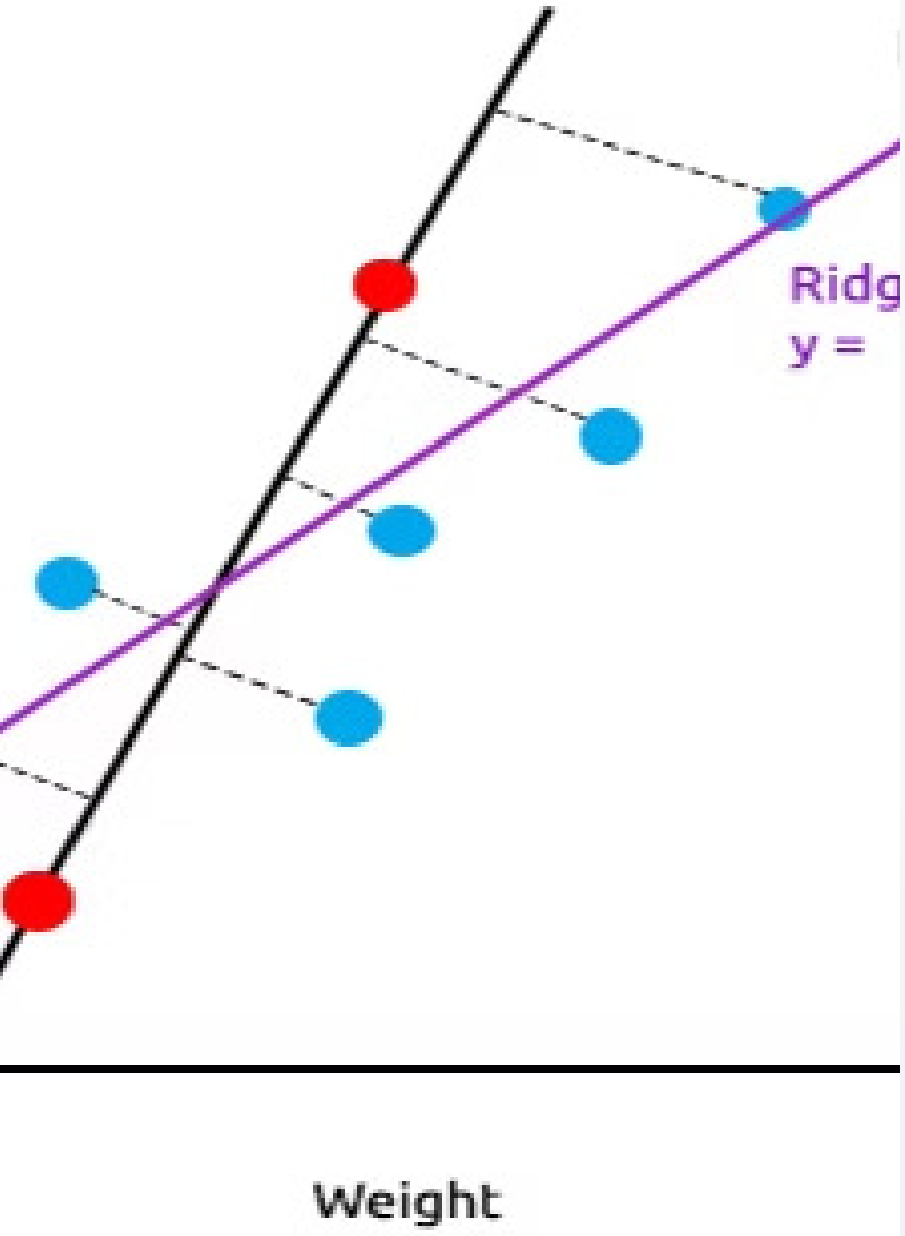

Objetivos

Nuestro objetivo principal es el de encontrar el mejor modelo de regresión y clasificación para predecir la variable de Carga de Calefacción. Para esto se entrenaran y compararan diversos modelos de machine learning.

1. Realizar un análisis y limpieza de los datos (EDA)
2. Crear modelos de regresion (Linear Regression, Ridge Regression, Random Forest y XGBoost) para predecir las variables y hallar el mejor
3. Crear modelos de clasificación para etiquetar automáticamente diseños como "Eficientes" (Carga < 14 kWh/m²) o "No Eficientes".

Made with GAMMA

Datos

1

768 edificios residenciales simulados

Se emplearon **768 edificios residenciales simulados** generados mediante el software Ecotect, el cual se estableció como la "verdad base" para el estudio. Para esta simulacion se tomo en cuenta como locacion la ciudad de Atenas (Grecia)

2

Algunos datos de la simulacion

Todos los edificios partieron de cubos elementales y mantuvieron el mismo volumen exacto (771.75 m^3), pero se configuraron en 12 formas y dimensiones diferentes. Donde se considero a que los edificios estaban habitados por 7 personas

3

8 Variables de Entrada

Compacidad relativa, área de superficie, área de pared, área de techo, altura total, orientación, área de acristalamiento (ventanas) y distribución del acristalamiento.

2 Variables de salida (y)

Carga de Calefaccion (HL) y carga de refrigeracion (CL)

4

Creacion de nueva Variable

Se creó la variable Overall_Surface (Área de Paredes + Área de Techo).

Justificación: Esta variable representa la superficie total expuesta al clima exterior, un principio básico de termodinámica que demostró altísima correlación con la pérdida de calor.

Made with GAMMA

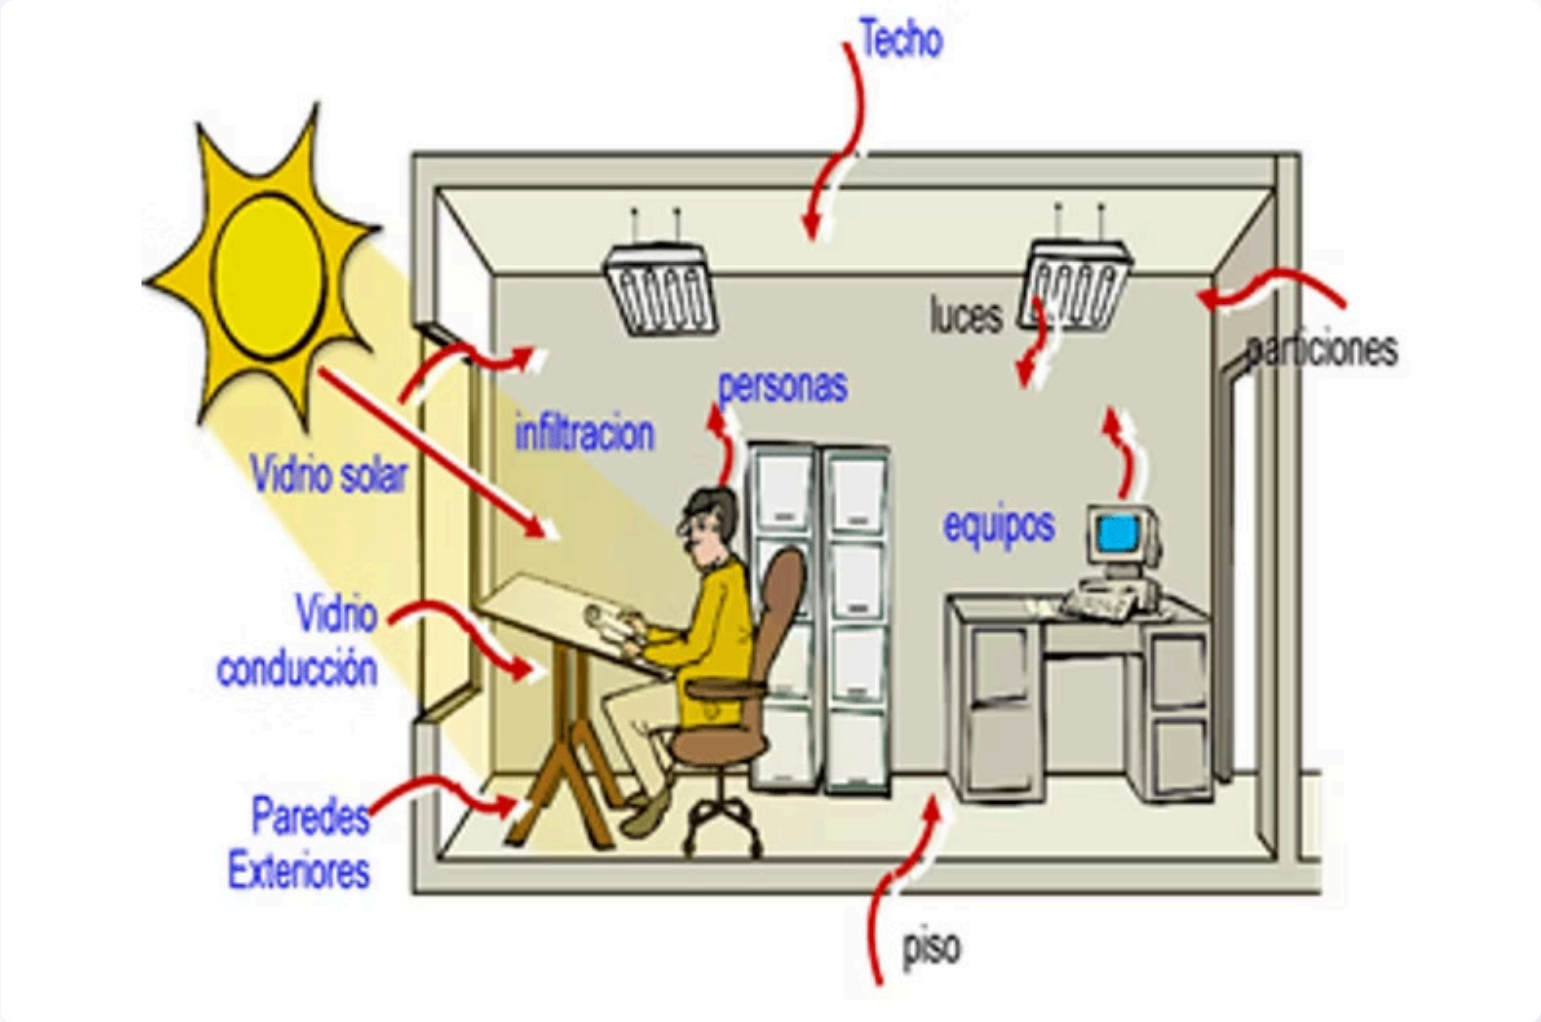

Made with GAMMA

Metodología

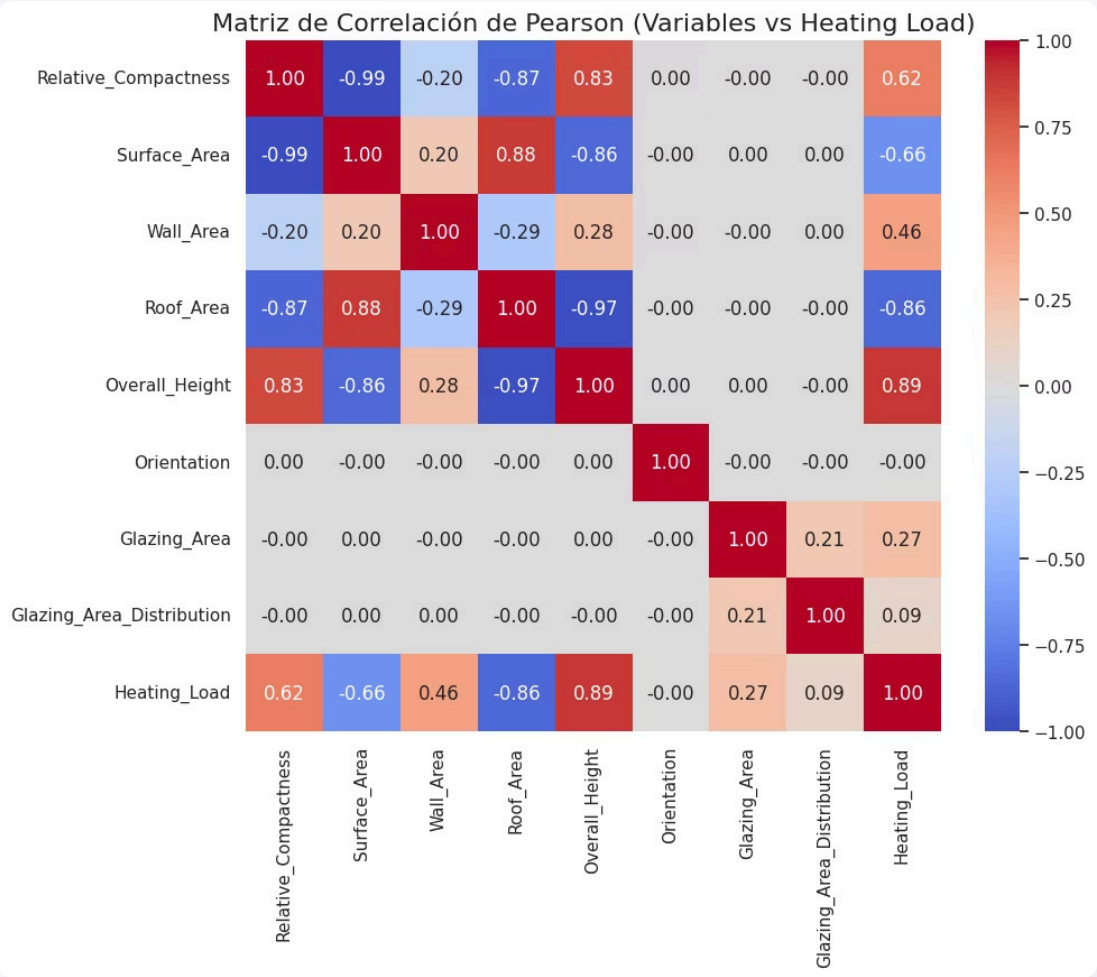

Exploración inicial: Se graficaron histogramas y diagramas de dispersión para explorar las propiedades estadísticas, comprobando que las variables no siguen una distribución normal (Gaussiana) y que su relación con el consumo de energía no es trivial.

Prevención de Data Leakage: Uso estricto de Pipelines en Python.

Pre-procesamiento: Estandarización de todas las variables numéricas (StandardScaler) antes del entrenamiento.

Validación: División de datos 80/20 y validación cruzada (K-Fold = 5) para asegurar que el modelo generalice correctamente en edificios nuevos.

Made with GAMMA

Metodología

- **Análisis estadístico:** Se aplicaron herramientas estadísticas como el coeficiente de correlación de rangos de Spearman y la Información Mutua (MI) para cuantificar la fuerza de la relación entre cada variable de diseño del edificio y su carga térmica.
- **Modelado (Machine Learning):** Se entrenaron y compararon dos enfoques de regresión para mapear las entradas con las salidas. El primero fue Mínimos Cuadrados Iterativamente Re-ponderados (IRLS), una técnica robusta que ajusta pesos para disminuir el efecto de los valores atípicos (outliers). El segundo modelo empleado fue la **Regresión Ridge**, una técnica de regularización lineal que añade una penalización a los coeficientes grandes; esto es particularmente útil en este contexto para manejar la alta correlación (multicolinealidad) que existe entre algunas variables de entrada, como el área del techo y la altura.
- **Optimización de Hiperparámetros:** Para maximizar el rendimiento de los modelos, se implementó una búsqueda aleatoria `RandomizedSearchCV`). Este proceso permitió encontrar la configuración óptima de los parámetros que controlan el aprendizaje.

Made with GAMMA

Resultados (Regression)

Los modelos de ensamble (**XGBoost** y **Random Forest**) superaron drásticamente al baseline lineal, reduciendo el RMSE de **2.93 a 0.36** y logrando un **R2 de 0.9987**.

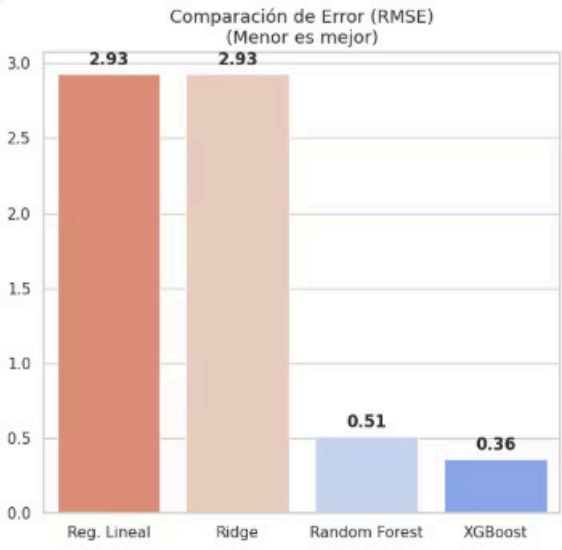

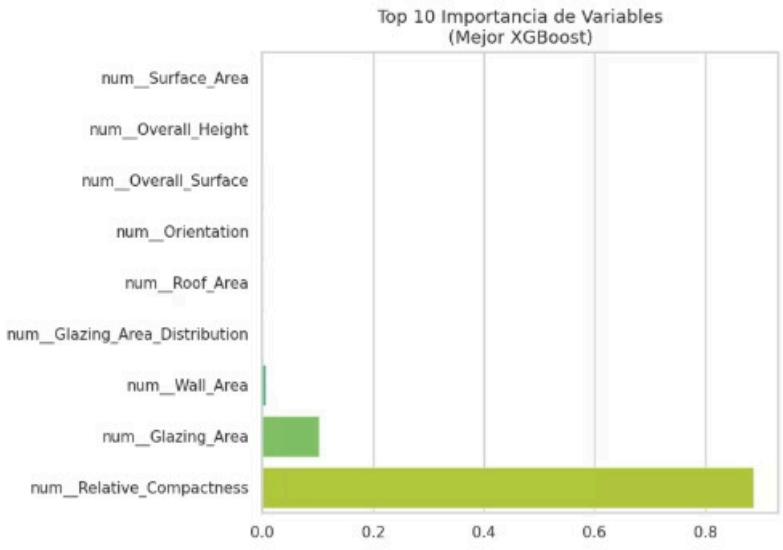

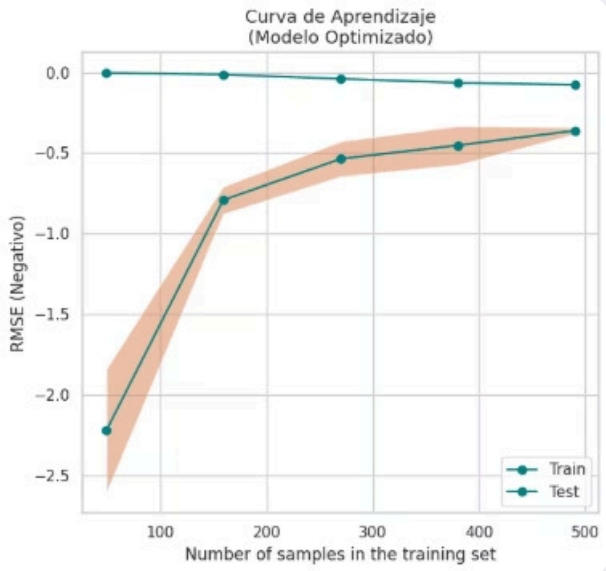

Made with GAMMA

Resultados (Clasificación)

Mediante el ajuste de hiperparámetros, el **Random Forest** alcanzó un **F1-Score de 0.9655** y un **ROC-AUC de 0.9990**, superando la capacidad de discriminación de la Regresión Logística (0.91). Este rendimiento casi perfecto garantiza la eliminación de **Falsos Positivos**, asegurando que cada edificio etiquetado como "Eficiente" cumpla estrictamente con los estándares térmicos.

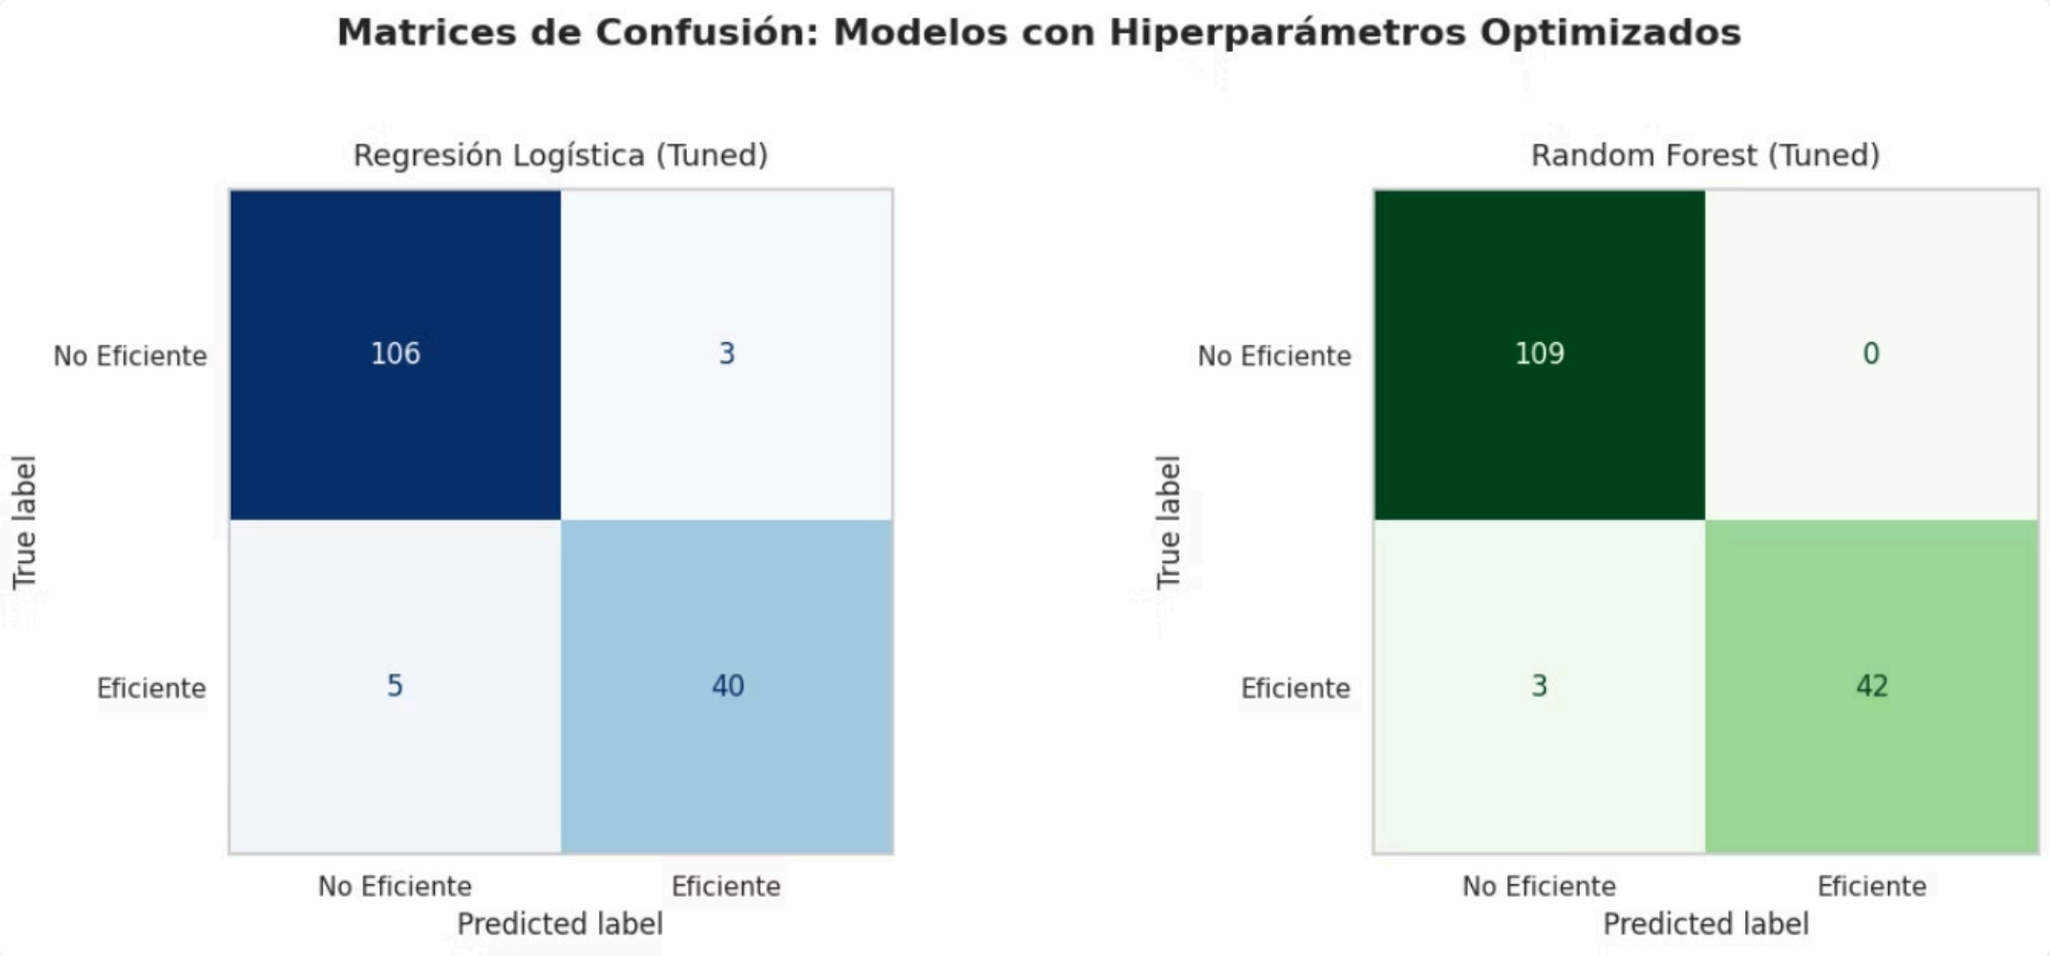

Made with GAMMA

Métricas

1. Altura Total (Overall Height): Es el factor dominante. Los saltos de 1 a 2 niveles disparan la demanda térmica.
2. Superficie Total (Overall Surface): Nuestra variable de ingeniería confirmó que la forma del edificio dicta su consumo.

Mito Desmentido: El área de vidrio (Glazing Area) tiene un impacto secundario comparado con la macro-geometría.

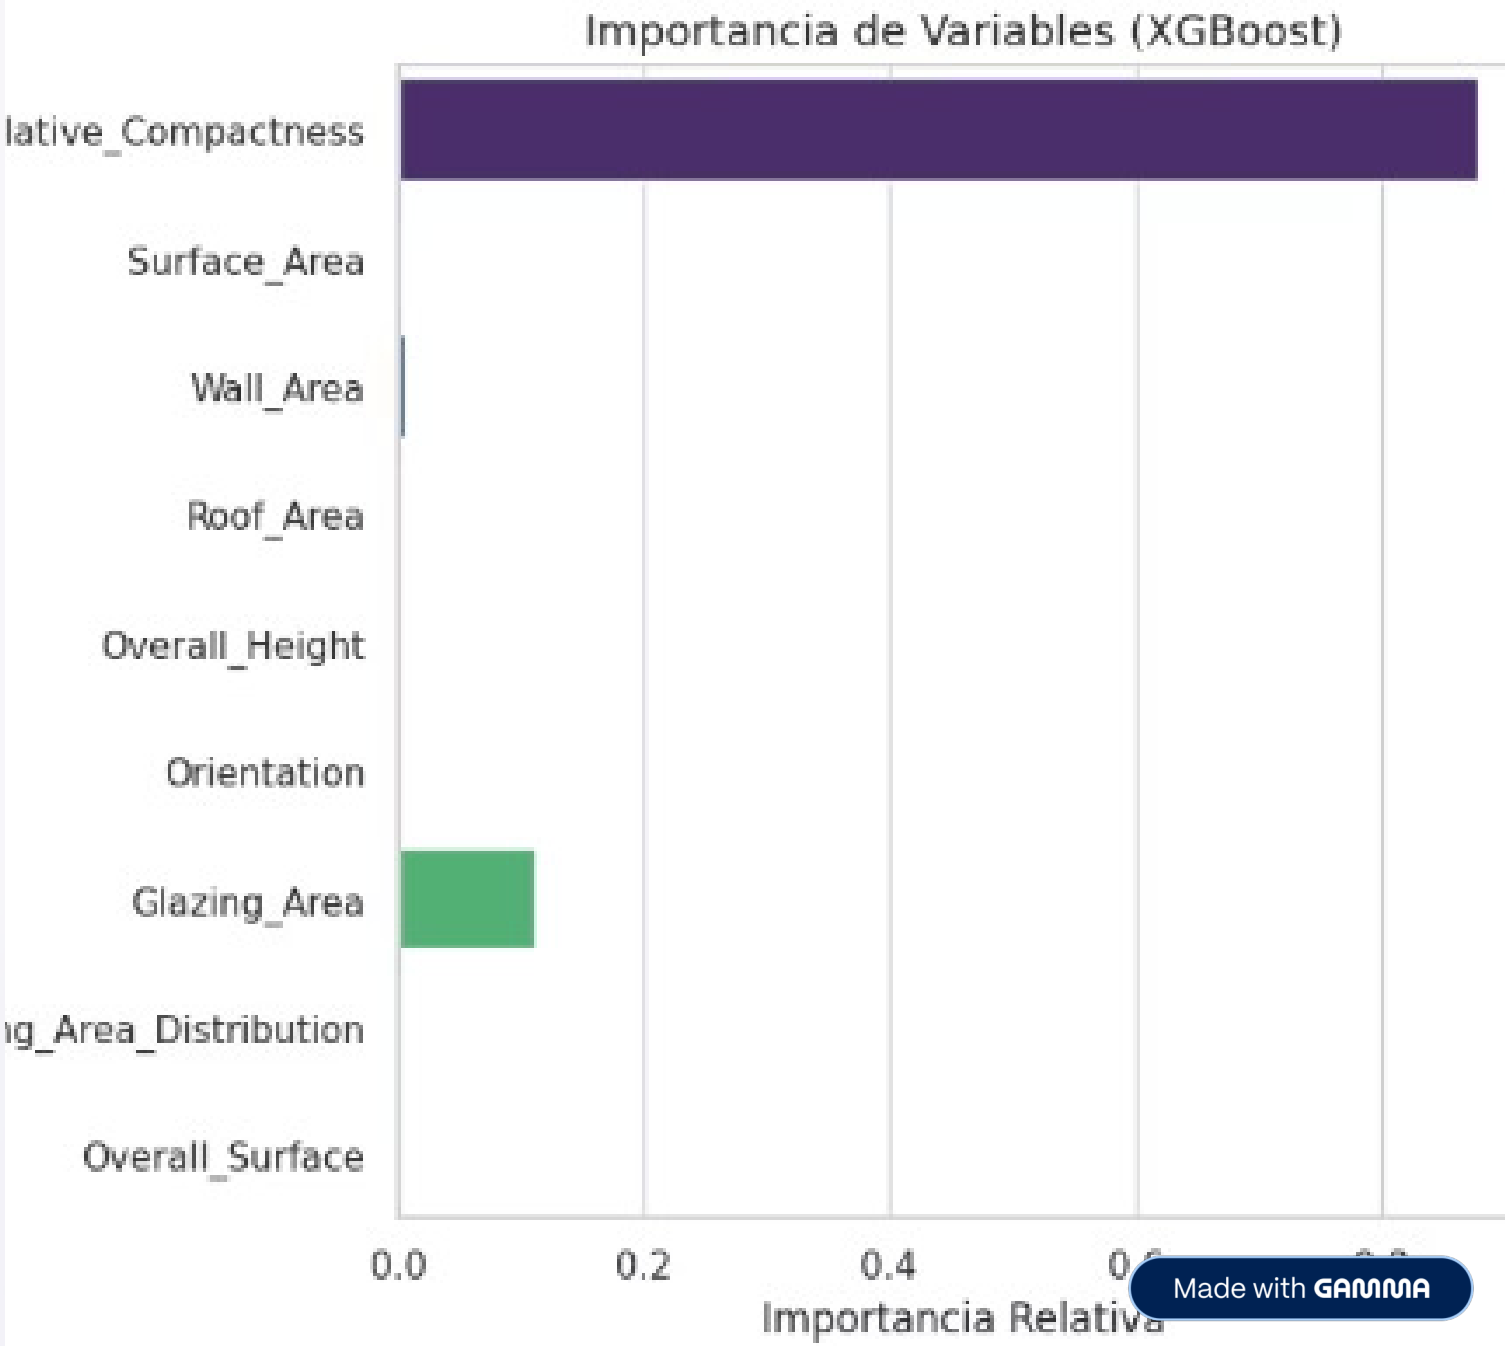

Made with GAMMA

Conclusiones

01

Predicción mediante machine learning

Las herramientas de aprendizaje automático (machine learning) pueden predecir con gran precisión la carga de calefacción y refrigeración de los edificios residenciales basándose únicamente en ocho variables de diseño

02

Variables más correlacionadas

La Compacidad Relativa y la Altura Total resultaron ser predictores dominantes. Los edificios con mayor altura (7 metros o dos niveles en este estudio) presentan una carga de calefacción significativamente superior. Esto indica que, para el mismo volumen, las construcciones más esbeltas pierden calor con mayor facilidad que aquellas más compactas.

03

Mejor modelo

El modelo de XGBoost resulto ser el más preciso para nuestro propósito, esto se logro demostrar mediante las diversas métricas obtenidas como el r2 score

04

Made with GAMMA

Recomendaciones

1 Priorizar diseños de perfil bajo

Favorecer construcciones de un solo nivel y plantas extendidas en climas fríos.

2 Priorizar la geometría antes que las ventanas

Optimizar la compacidad y la superficie total expuesta antes de invertir en ventanas termoacústicas de lujo.

3 Priorizar la compacidad del diseño

En zonas climáticas frías, se deben favorecer diseños con alta compacidad relativa (estructuras más cercanas a un cubo o esfera) para reducir el área de superficie expuesta a la intemperie.

Made with GAMMA

GRACIAS

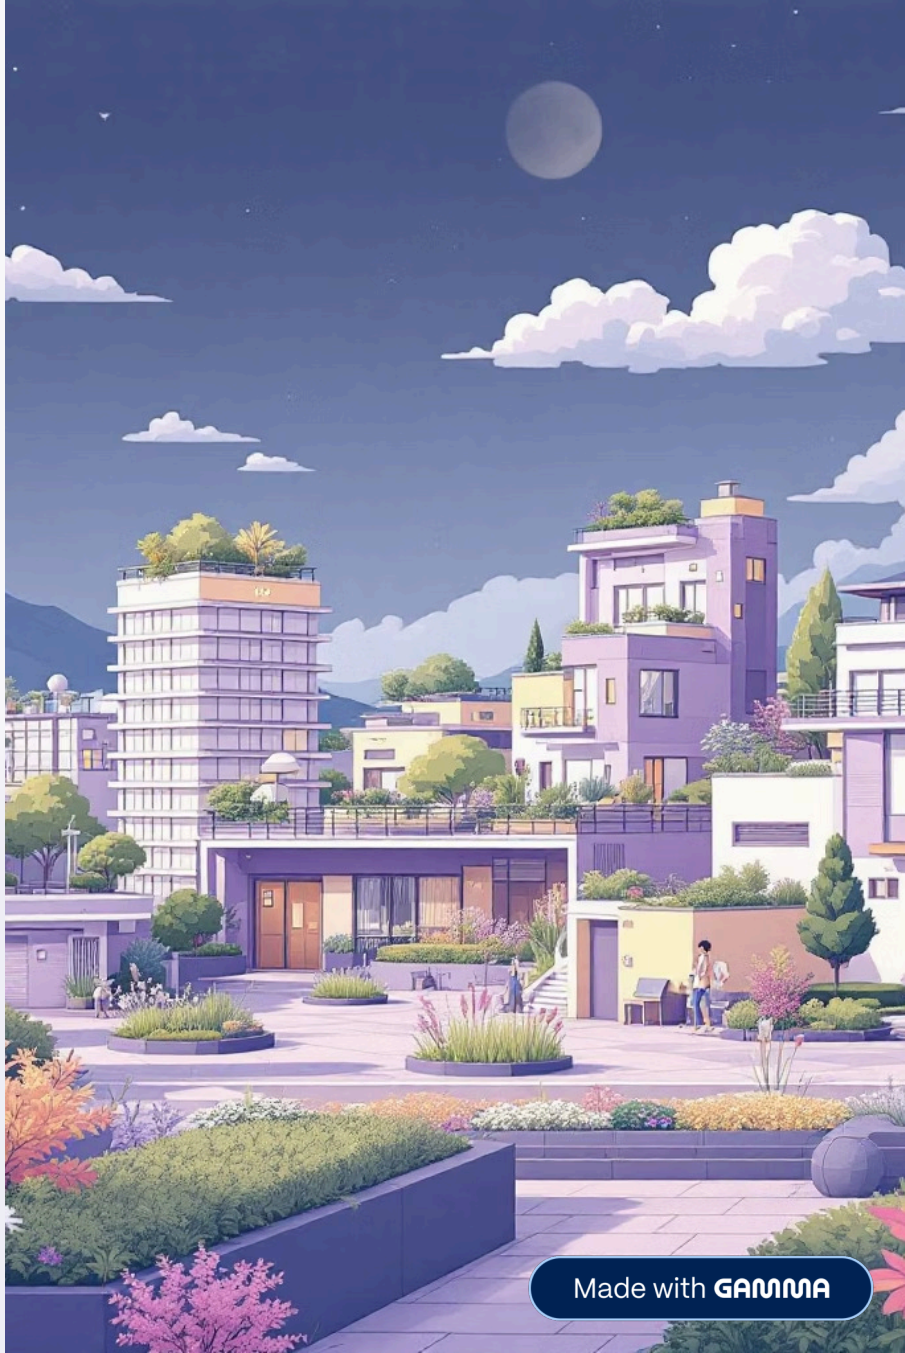

Made with GAMMA