Optimización de Eficiencia Energética en Edificios

Predicción de Carga Térmica mediante Machine Learning (Enfoque CRISP-DM)

Equipo: Consultoría de Eficiencia Energética (LEED)

Integrantes:

- Lopez Castillo Kael Alessandro
- Medina Paredes Esmeralda Paula
- Torrez Calle Álvaro Ariel

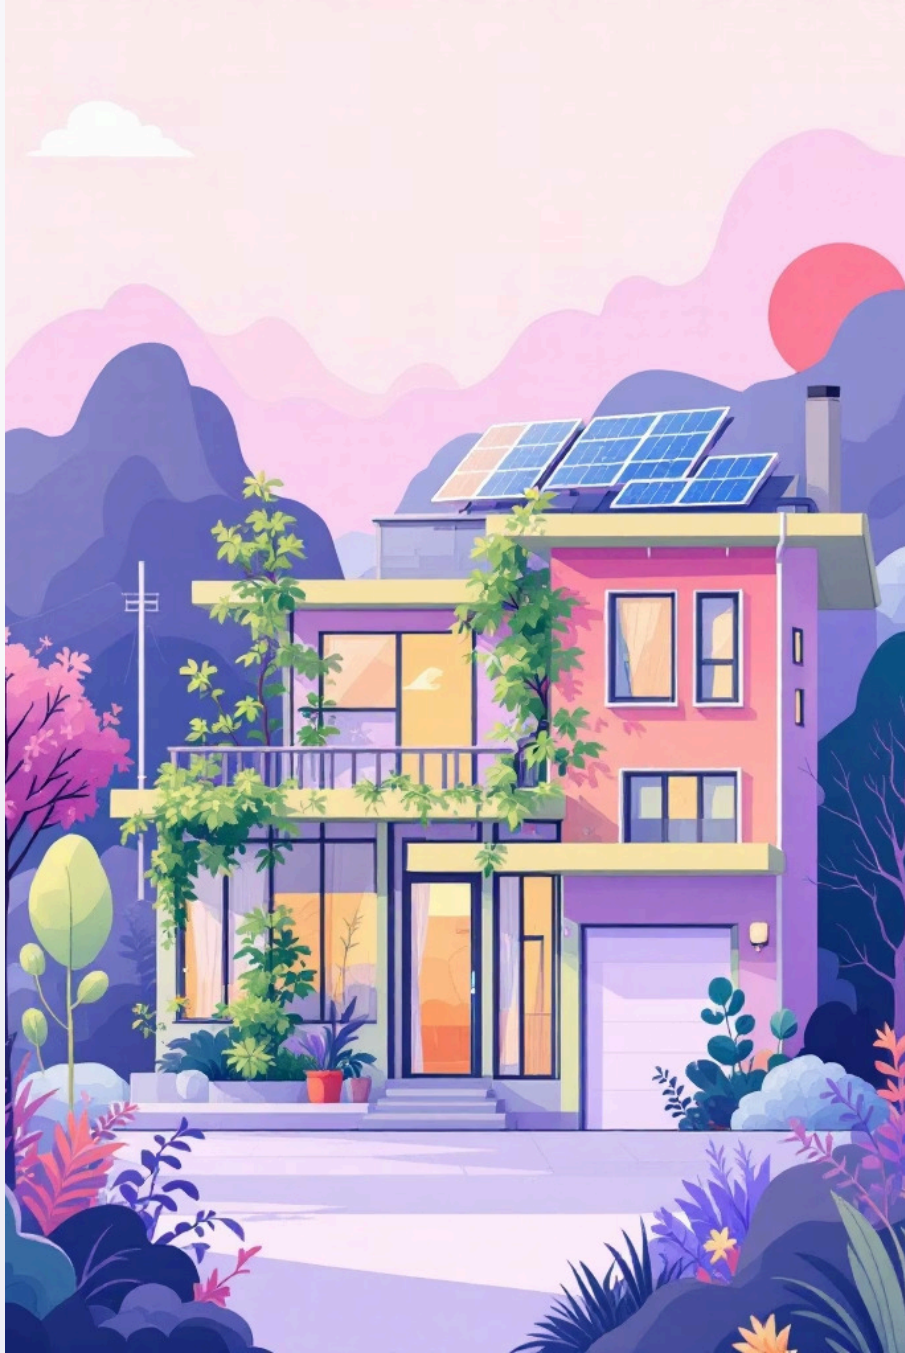

Contexto del Proyecto

- Los sistemas de climatización (HVAC) son el mayor gasto energético en edificios residenciales.
- Existen 2 parametros que definen la ediciencia de un edificio: la carga de calefacción (HL) y la carga de refrigeración (CL).
- Tradicionalmente, esto se hace usando software de simulación de energía que consume mucho tiempo y requiere conocimientos técnicos altamente especializados.

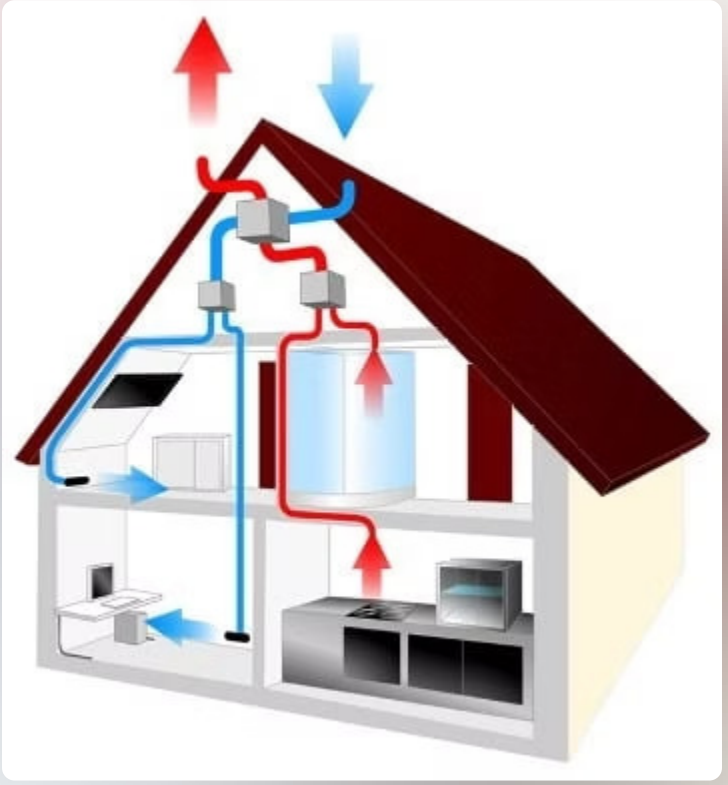

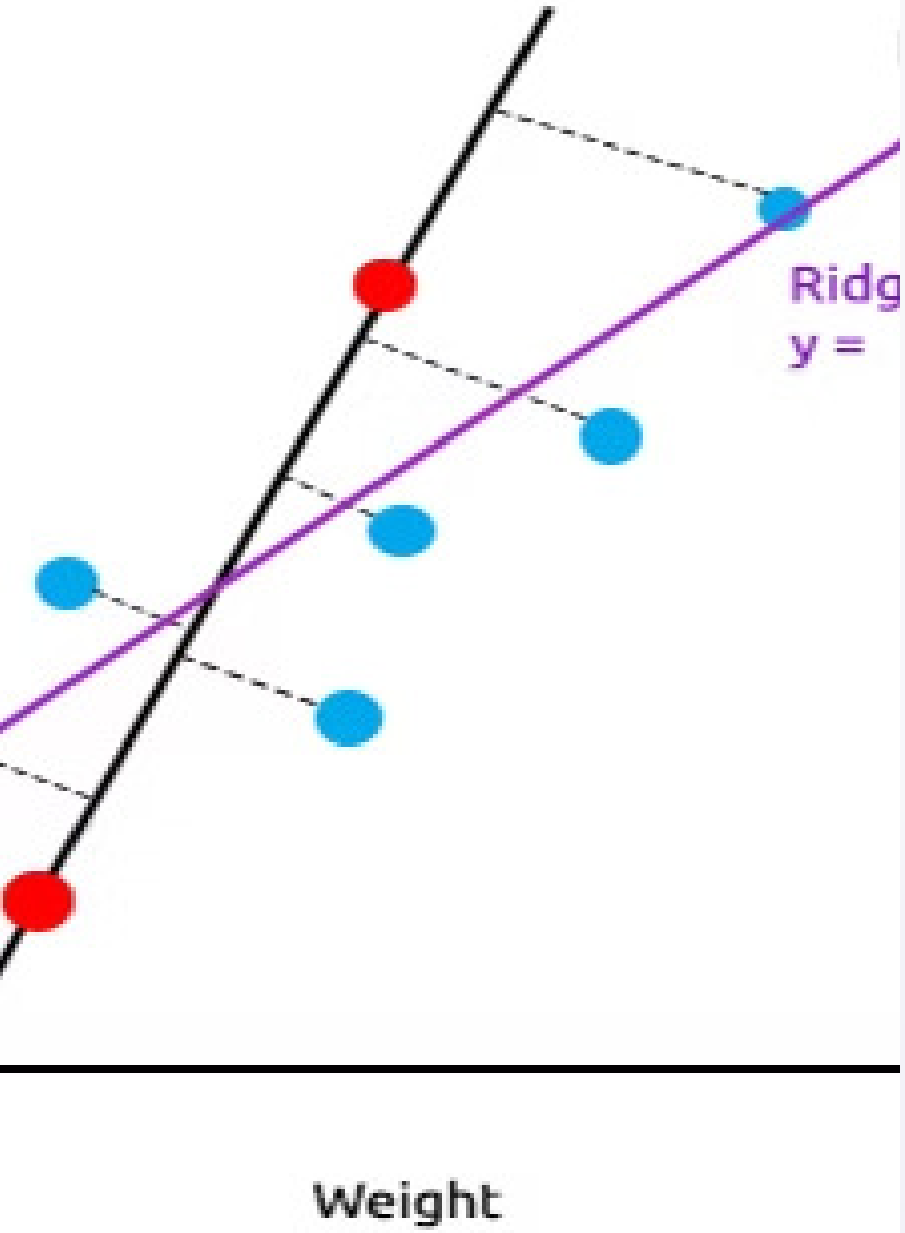

Objetivos

Nuestro objetivo principal es el de encontrar el mejor modelo de regresion y clasificacion para predecir la variable de Carga de Calefaccion. Para esto se entrenaran y compararan diversos modelos de machine learning.

1. Realizar un analisis y limpieza de los datos (EDA)
2. Crear modelos de regresion (linear regresion, ridge regresion, random forest) para predecir las variables y hallar el mejor
3. Crear modelos de clasificacion para etiquetar automáticamente diseños como "Eficientes" (Carga < 14 kWh/m²) o "No Eficientes".

Datos

768 edificios residenciales simulados

Se emplearon **768 edificios residenciales simulados** generados mediante el software Ecotect, el cual se estableció como la "verdad base" para el estudio. Para esta simulacion se tomo en cuenta como locacion la ciudad de Atenas (Grecia)

Algunos datos de la simulacion

Todos los edificios partieron de cubos elementales y mantuvieron el mismo volumen exacto (771.75 m^3), pero se configuraron en 12 formas y dimensiones diferentes. Donde se considero a que los edificios estaban habitados por 7 personas

8 Variables de Entrada

Compacidad relativa, área de superficie, área de pared, área de techo, altura total, orientación, área de acristalamiento (ventanas) y distribución del acristalamiento.

2 Variables de salida (y)

Carga de Calefaccion (HL) y carga de refrigeracion (CL)

Creacion de nueva Variable

Se creó la variable Overall_Surface (Área de Paredes + Área de Techo).

Justificación: Esta variable representa la superficie total expuesta al clima exterior, un principio básico de termodinámica que demostró altísima correlación con la pérdida de calor.

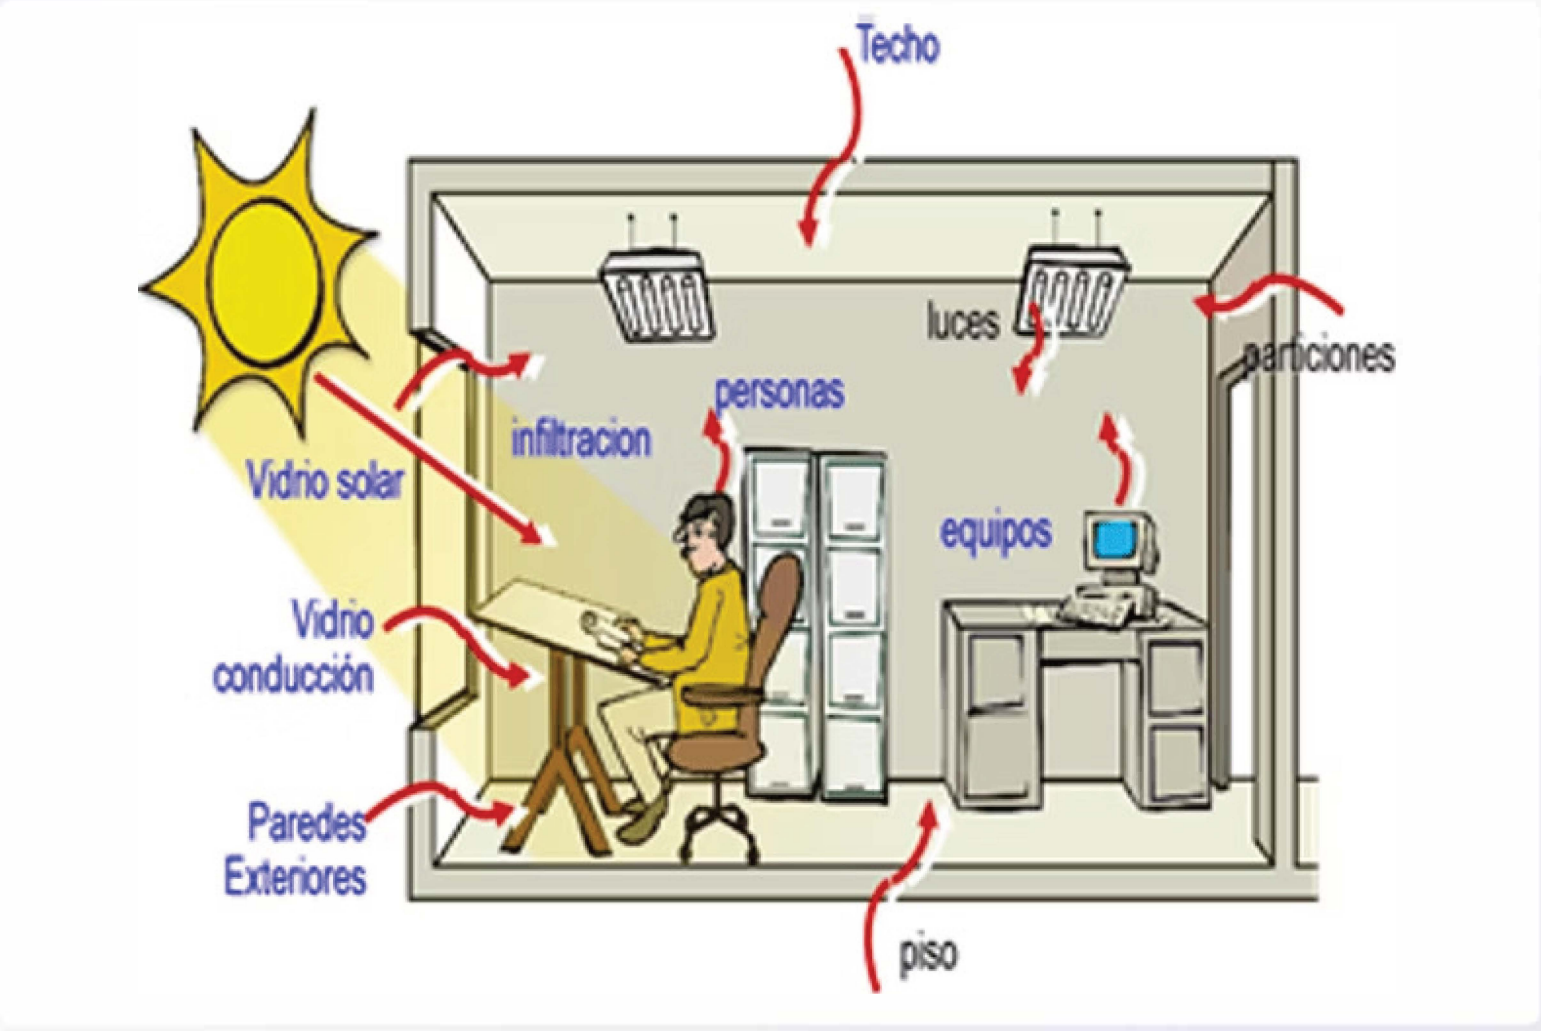
Techo
luces
particiones
personas
infiltracion
Vidrio solar
equipos
Vidrio
conducción
Paredes
Exteriores
piso

Metodologia

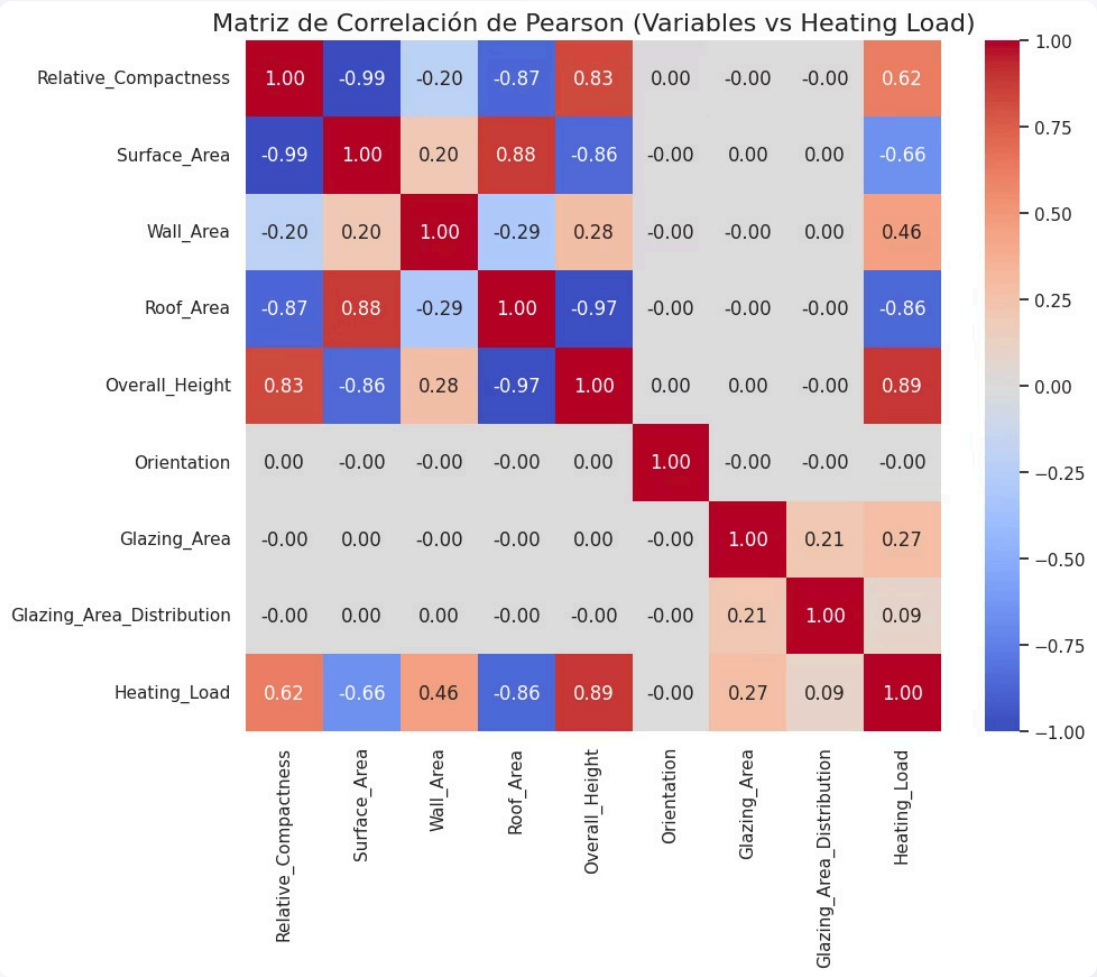

Exploración inicial: Se graficaron histogramas y diagramas de dispersión para explorar las propiedades estadísticas, comprobando que las variables no siguen una distribución normal (Gaussiana) y que su relación con el consumo de energía no es trivial.

Prevención de Data Leakage: Uso estricto de Pipelines en Python.

Preprocesamiento: Estandarización de todas las variables numéricas (StandardScaler) antes del entrenamiento.

Validación: División de datos 80/20 y validación cruzada (K-Fold = 5) para asegurar que el modelo generalice correctamente en edificios nuevos.

Metodología

- **Análisis estadístico:** Se aplicaron herramientas estadísticas como el coeficiente de correlación de rangos de Spearman y la Información Mutua (MI) para cuantificar la fuerza de la relación entre cada variable de diseño del edificio y su carga térmica.
- **Modelado (Machine Learning):** Se entrenaron y compararon dos enfoques de regresión para mapear las entradas con las salidas. El primero fue Mínimos Cuadrados Iterativamente Re-ponderados (IRLS), una técnica robusta que ajusta pesos para disminuir el efecto de los valores atípicos (outliers). El segundo modelo empleado fue la **Regresión Ridge**, una técnica de regularización lineal que añade una penalización a los coeficientes grandes; esto es particularmente útil en este contexto para manejar la alta correlación (multicolinealidad) que existe entre algunas variables de entrada, como el área del techo y la altura.

Resultados (Regresion)

El modelo Random Forest aprende rápidamente y se estabiliza.

No presenta sobreajuste (overfitting) severo, validando que nuestra metodología de separación de datos fue un éxito.

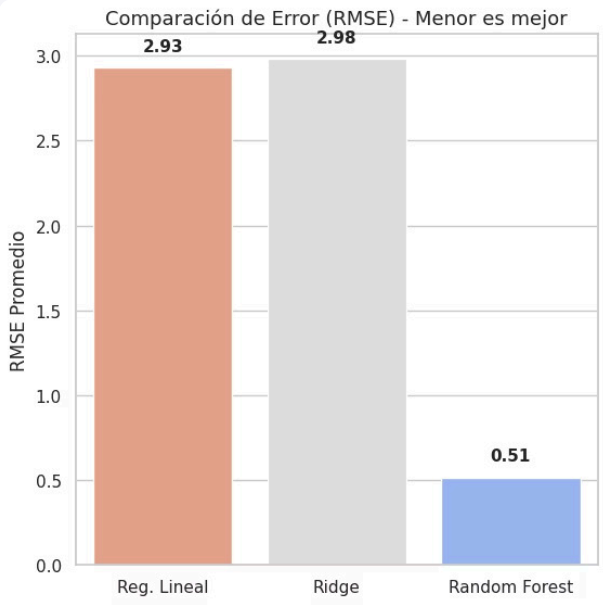

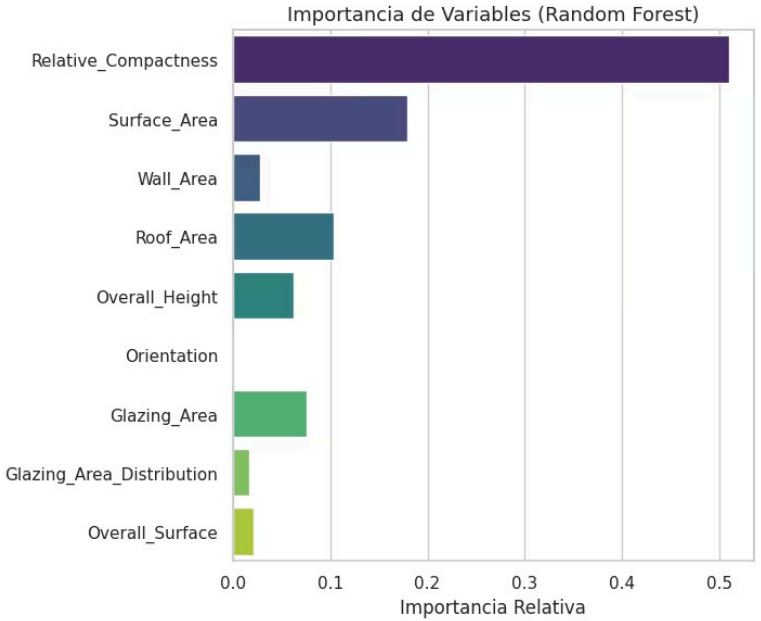

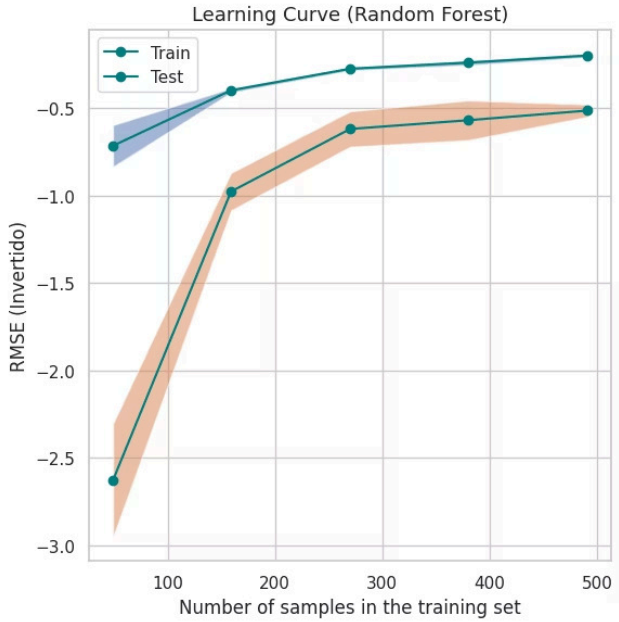

Resultados (Clasificacion)

Para la clasificacion se tomo en cuenta a los modelos de regresion logistica y random forest con los cuales se lograron los siguientes resultados:

Baseline (Regresión Logística): F1-Score: 0.96 | ROC-AUC: 0.99

Modelo Avanzado (Random Forest Classifier): F1-Score: 1.00 | ROC-AUC: 1.00

Logro de Negocio: El modelo logró una precisión perfecta en el set de prueba, eliminando por completo los Falsos Positivos.

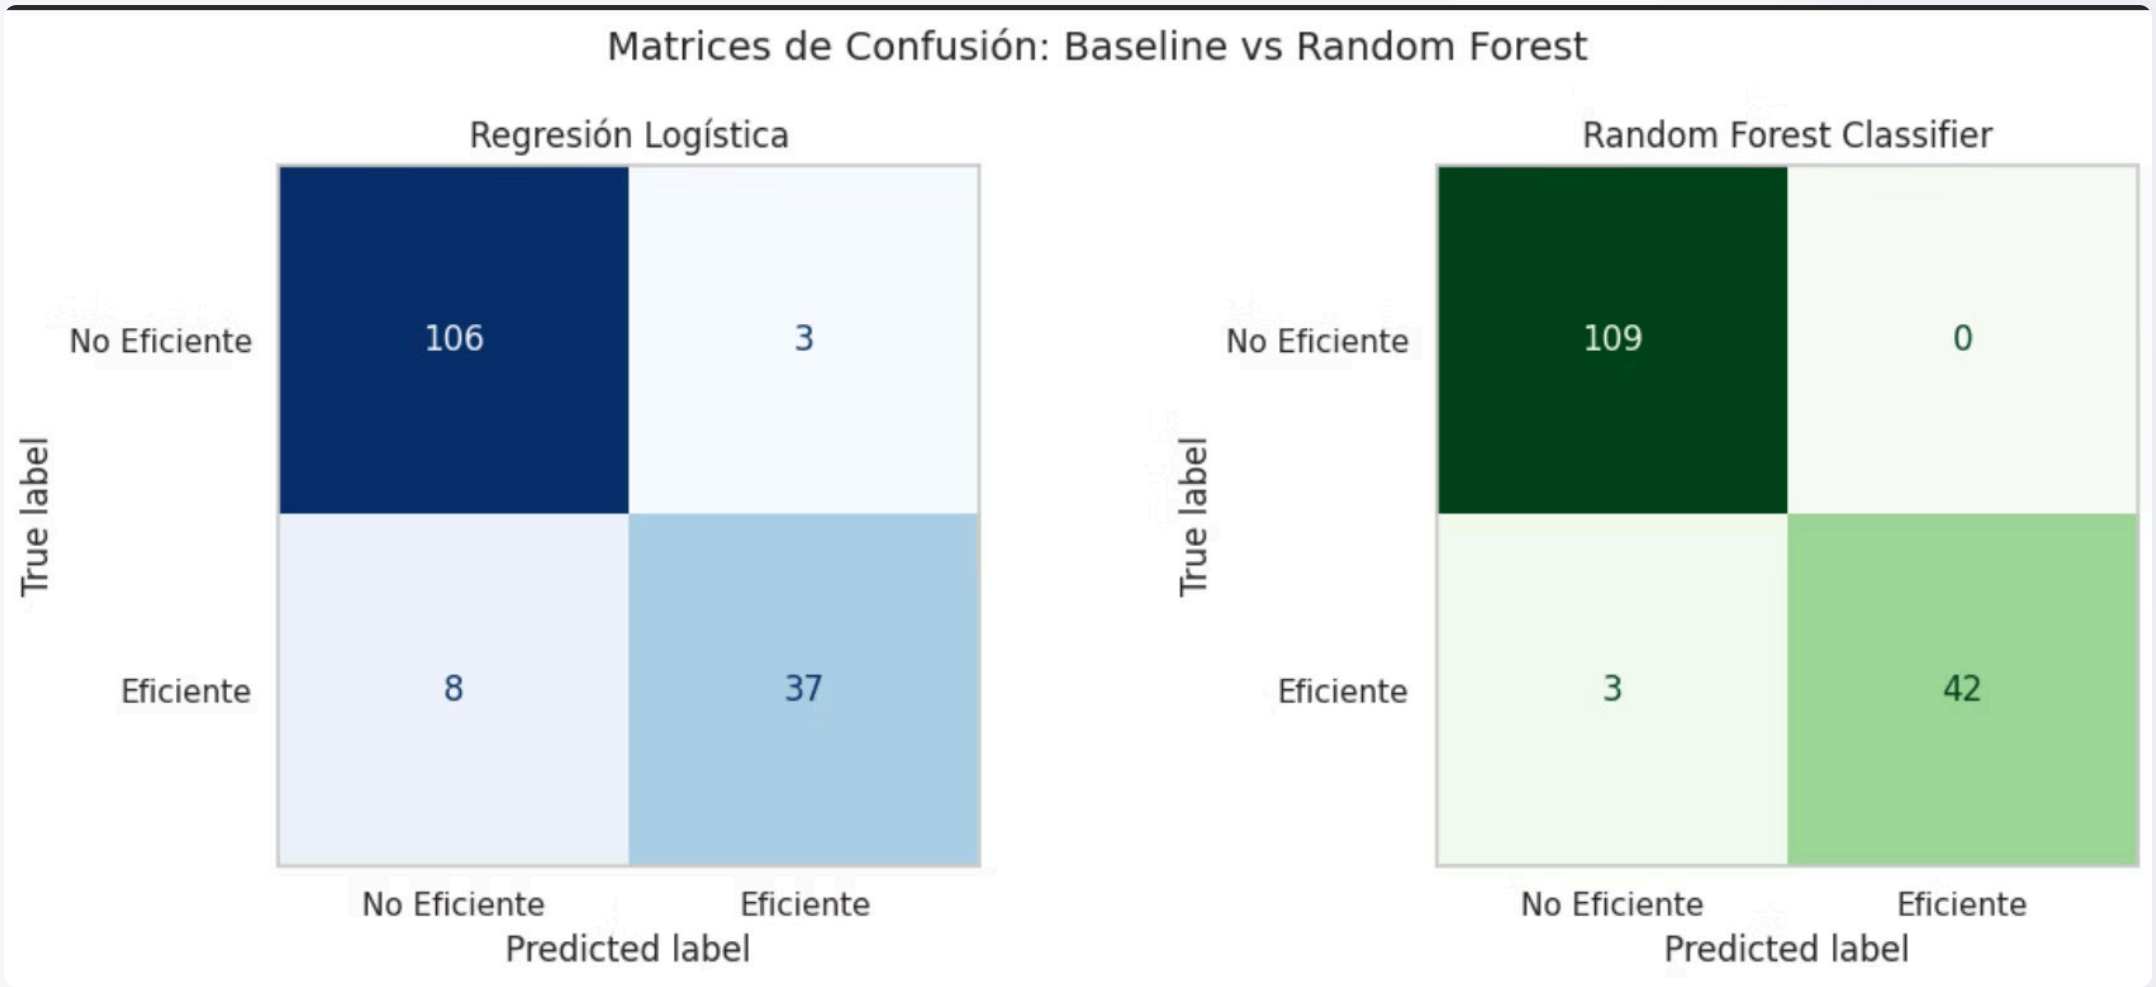

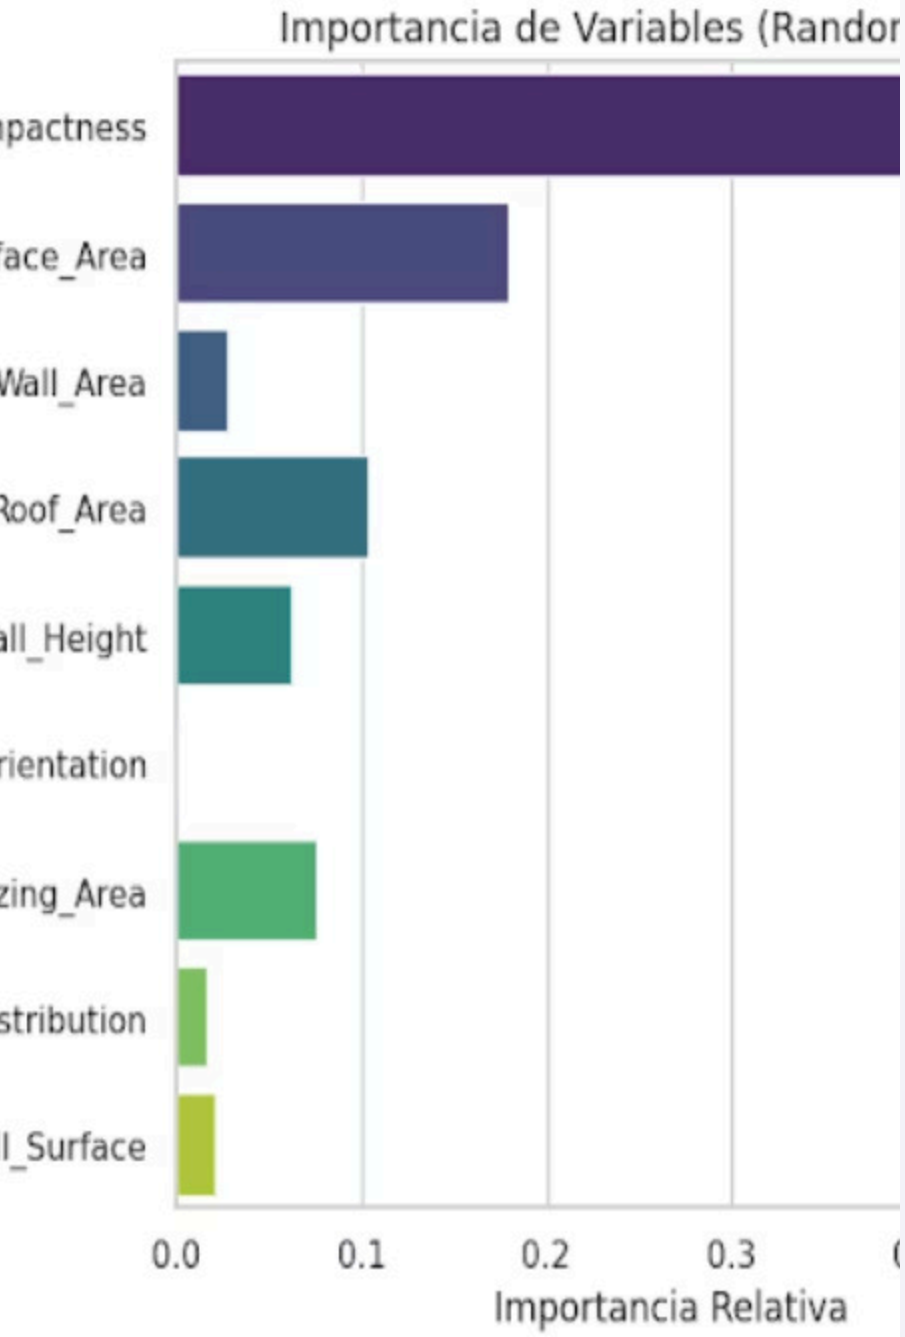

Metricas

1. Altura Total (Overall Height): Es el factor dominante. Los saltos de 1 a 2 niveles disparan la demanda térmica.
2. Superficie Total (Overall Surface): Nuestra variable de ingeniería confirmó que la forma del edificio dicta su consumo.

Mito Desmentido: El área de vidrio (Glazing Area) tiene un impacto secundario comparado con la macro-geometría.

Conclusiones

01

Prediccion mediante machine learning

Las herramientas de aprendizaje automático (machine learning) pueden predecir con gran precisión la carga de calefacción y refrigeración de los edificios residenciales basándose únicamente en ocho variables de diseño

02

Variables mas correlacionadas

La Compacidad Relativa y la Altura Total resultaron ser predictores dominantes. Los edificios con mayor altura (7 metros o dos niveles en este estudio) presentan una carga de calefacción significativamente superior. Esto indica que, para el mismo volumen, las construcciones más esbeltas pierden calor con mayor facilidad que aquellas más compactas.

03

Mejor modelo

El modelo de Random Forest resulto ser el mas preciso para nuestro proposito, esto se logro demostrar mediante las diversas metricas obtenidas como el r2 score

04

Recomendaciones

1 Priorizar diseños de perfil bajo

Favorecer construcciones de un solo nivel y plantas extendidas en climas fríos.

2 Priorizar la geometria antes que las ventanas

Optimizar la compacidad y la superficie total expuesta antes de invertir en ventanas termoacústicas de lujo.

3 Priorizar la compacidad del diseño

En zonas climáticas frías, se deben favorecer diseños con alta compacidad relativa (estructuras más cercanas a un cubo o esfera) para reducir el área de superficie expuesta a la intemperie.